

理论与方法

本文从置换不变量环的代数生成问题出发，将势能面描述符的目标放宽为对物理构型轨道的分离，并据此构造一种按照关联阶与递推深度组织的置换不变量。理论上严格可分的不变量集为方法提供设计目标；实际计算则采用有限关联阶与有限递推深度的截断，在严格置换不变的前提下寻求精度与计算成本之间的平衡。因此，除非另有证明，本文不把任意有限截断描述符宣称为全局严格可分集。

1. 代数完备性与可分性

设 G 为全同原子的置换群。对于一组 G -不变多项式 $F = \{f_1, f_2, \dots, f_W\}$ ，如果它满足代数完备性，就能够通过多元多项式运算生成所有不变量。也就是说，任意置换不变多项式 $P(x_1, \dots, x_L)$ 都可以写成 $P = P'(f_1, f_2, \dots, f_W)$ ，其中 P' 是一个多元多项式。基本不变量多项式 (FI) 是关于键长的一组最小代数完备置换不变量。其数量显著少于原始的 PIP，是一种更精简的神经网络势能面描述符。由于每个 PIP 都可以表示为 FI 的多项式，任何以 PIP 为输入的神经网络函数都可以等价地改写为 FI 的函数。当然，这种理论表达能力上的等价并不保证二者在实际拟合中获得相同的精度。

然而对于大体系，FI 集合引入的计算代价也很高。此时我们认为，对于神经网络势能面描述符而言，代数完备性也是一个有内在冗余的要求，一组达成构型可分性的多项式集合可能已经足够。

可分性是一种忽略对称等价后的单射性，意味着一个多项式集合在不同的群作用轨道上具有不同的取值向量。我们可以把多项式集合视为一个从 $\mathbb{R}^L$ 到 $\mathbb{R}^W$ 的矢量函数：

$$\mathbf{F}(\vec{x}) = (f_1(\vec{x}), f_2(\vec{x}), \dots, f_W(\vec{x}))^\top.$$

我们可以进一步定义键长矢量空间 $(r_{1,2}, r_{1,3}, \dots, r_{1,N}, \dots, r_{N-1,N})$ 上的可分性。如果存在 $\sigma \in G$ 使两个键长矢量满足 $A = \sigma B$ ，那么我们就称 A 和 B 等价；用群论的语言说，它们处于同一个群作用轨道内。置换不变多项式在同一个等价类或轨道上必然具有相同的值。如果对于任意两个不等价的键长矢量，存在至少一个多项式 f_j 在它们上的取值不同，我们就称这组置换不变多项式是可分的。

代数完备必然推出键长矢量空间上的轨道可分，反之则不成立。换言之，可分性是更弱的要求，因此最小可分集合可能比最小代数生成集更小。甲醛给出了一个简单例子。它只允许交换两个氢原子，并具有如下最小代数生成元集合：

$$\begin{aligned} F_{\text{FI}} &= \{r_{\text{CO}}, r_{\text{H}_1\text{H}_2}, a, b, q, p, s\}, \\ a &= r_{\text{CH}_1} + r_{\text{CH}_2}, & u &= r_{\text{CH}_1} - r_{\text{CH}_2}, \\ b &= r_{\text{OH}_1} + r_{\text{OH}_2}, & v &= r_{\text{OH}_1} - r_{\text{OH}_2}, \\ q &= u^2 - v^2, & p &= 2uv, & s &= u^2 + v^2. \end{aligned}$$

然而删除 s 之后，剩余的 6 个元素依然能够分离全部实键长轨道；换言之，对于任意两个在置换作用下不等价的键长矢量，剩余的 6 个多项式中至少有一个会给出不同的值。SI 第 S2-S3 节给出了关于代数完备性与可分性的详细讨论。本工作以可分性而非代数完备性作为进一步压缩多项式数量和长度的理论目标。实际采用的有限截断严格保持置换不变性，但不预设其已经达到全局严格可分。

但是值得注意的是，键长矢量可分性与物理构型可分性并不相同。对于 $(\mathbb{R}^3)^N$ 中的笛卡尔坐标矢量，全同原子置换群 G 与三维欧氏群 $E(3)$ 的联合作用定义了物理等价关系，每一个轨道对应一个物理构型。如果对于任意两个不等价的物理构型，存在至少一个多项式 f_j 在它们对应的键长矢量上取值不同，我们就称这组置换不变多项式是物理构型可分的。在整个抽象键长矢量空间上要求可分，是物理构型可分的充分而非必要条件；对于

势能面拟合而言，后者才是理论上真正需要的最小性质，因为抽象键长空间中的许多组合并不对应实际的物理构型。

2. 幂和：键值多重集恢复及其局限

关于键长的某个标量函数的幂和多项式计算成本低廉，并且可以提供大量但是并不严格的可分性。所以它可以作为我们新的方法的基础。我们接下来讨论幂和

对 M 个变量函数可以定义幂和

$$p_n(x) = \sum_{i=1}^M x_i^n, \quad n = 1, \dots, M.$$

若只计算前 D 阶，可在逐变量层面递推

$$x_i^{n+1} = x_i^n x_i,$$

并在每阶累加。总时间复杂度为 $O(MD)$ ，工作内存可保持为 $O(M)$ 。完整递推到 $D = M$ 时，时间复杂度为 $O(M^2)$ 。

对于多元素体系，可以按照元素对类别对全部原子间距离进行分组，并为每一组独立构造幂和。为使讨论简明，以下假定体系仅含一种元素。此时 N 个全同原子具有 $M = \binom{N}{2}$ 条距离，完整的前 M 个幂和能够唯一确定这些键值的无序多重集，详细证明见 SI 第 S4 节。所谓无序多重集，是指只保留每个键值及其出现次数，而不记录它在键长矢量中的位置或属于哪一对原子；例如 (a, b, a) 对应的无序多重集为 $\{a, a, b\}$ 。然而，从键长矢量降为无序多重集会舍弃各分量的位置和原子归属，因而一般不能保证键长矢量或物理构型的全局严格可分性。

这种信息损失可以理解为过度对称化。任意原子置换 S_N 会在 M 条距离上诱导一个置换群 $\rho(S_N)$ ，但当 $N \geq 4$ 时，

$$\rho(S_N) \subsetneq S_M.$$

完整幂和对全部 M 条距离的任意重排都保持不变，因此能够分离 S_M 的不同轨道；然而真实的分子对称性只有较小的 $\rho(S_N)$ 。同一个 S_M 轨道可能包含多个彼此不等价的 $\rho(S_N)$ 轨道，而幂和无法区分它们。

我们用另外一个4原子的例子说明幂和多项式无法提供严格的构型可分性。考虑四个全同原子和六条两两距离。取两个正数 $a \neq b$ ，定义三种边长分配：

$$\begin{aligned} A: & \quad r_{12} = r_{13} = r_{14} = a, \\ B: & \quad r_{12} = r_{13} = r_{23} = a, \\ C: & \quad r_{12} = r_{23} = r_{34} = a, \end{aligned}$$

其余三条边均取 b 。三种分配中，取值为 a 的边分别呈星形、三角形和三边路径式排列。三者具有完全相同的无标号边值多重集

$$\{a, a, a, b, b, b\},$$

故对任意 $n \geq 1$,

$$p_n(A) = p_n(B) = p_n(C) = 3a^n + 3b^n.$$

然而三种边长邻接关系不同，不存在原子置换将其相互变换，因此它们属于不同的 S_4 构型轨道。而且这不是由非物理边长制造的反例。取 $a = \sqrt{2}$, $b = 1$ 时，三种分配均对应非退化的三维构型；其 Gram 矩阵谱和关联量见 SI 第 S6 节。

3. 幂和的物理构型可分性

上一节四原子反例表明，即使使用完整幂和，也不能在整个键长矢量空间中保证严格的构型可分性。然而，物理距离并不是任意的正数集合。一个含有 N 个原子的三维构型在除去整体平移和转动后通常具有 $3N - 6$ 个自由度，而两两距离的数目为 $M = \binom{N}{2}$ 。二者之差为

$$M - (3N - 6) = \frac{(N - 3)(N - 4)}{2}.$$

当 $N = 4$ 时，这一差值为零，非退化物理距离在局部没有额外的等式型约束；这与上一节的反例一致，同一组无标号距离可以按照不同方式分配给四面体的六条边，并仍然得到合法构型。当 $N \geq 5$ 时，物理距离之间必须满足额外的几何约束，大多数任意的键值重排不再对应三维构型。换言之，幂和在抽象键长空间中引入的许多额外等价关系，在限制到物理距离域后会自然消失。

Boutin 和 Kemper 的构型重构结果进一步表明，对于 $N \geq 5$ 的三维一般位置构型，完整的无标号两两距离多重集可以唯一确定物理构型，允许相差整体平移、转动、反射和全同原子的重新编号。这里的“一般位置”不是某一种特定的几何排列，而是指构型位于由特殊坐标或距离关系定义的低维代数例外集合之外；无标号距离的重构歧义只可能出现在该例外集合中，而这一集合在连续构型空间中具有零测度。换言之，若从具有连续概率密度的构型分布中随机抽样，抽到这些例外构型的概率为 0。

若键长变换 $u(r)$ 是单射的，完整的前 M 个幂和可以恢复 $\{\{u(r_{ij})\}\}$ 。因此，幂和所包含的信息可以概括为

$$(p_1, \dots, p_M) \implies \{\{u(r_{ij})\}\} \implies \text{物理构型}, \quad N \geq 5,$$

其中第一个箭头严格成立，第二个箭头对一般位置构型成立。因此，完整幂和以概率 1 分离从连续分布中随机采样的物理构型。这一结论说明，尽管幂和不是全局严格可分的，它仍然保留了远多于四原子反例表面上显示的构型信息。

但是，概率 1 的可分性并不足以保证幂和是一个稳定而易于拟合的势能描述符。记完整幂和描述符为 $\Phi(Q)$ 。如果两个不等价构型 A 和 B 满足

$$\Phi(A) = \Phi(B) = \mathbf{p}, \quad V(A) \neq V(B),$$

那么势能不能在描述符点 $\mathbf{p}$ 上定义为一个单值函数。更重要的是，取分别趋近于 A 和 B 的构型序列 A_n 和 B_n ，描述符的连续性给出

$$\Phi(A_n), \Phi(B_n) \longrightarrow \mathbf{p},$$

而能量可以趋向两个不同的极限。于是，在 $\mathbf{p}$ 的任意小邻域内都可能出现描述符非常接近但能量明显不同的构型。严格碰撞集合即使具有零测度，也可能在其邻域造成近碰撞和很差的逆映射条件，从而增加有限容量回归模型的拟合难度。

此外，上述泛型可分结论要求完整的前 M 个幂和，不能直接推广到实际使用的有限阶截断 $D < M$ 。因此，完整幂和提供的是一种很强但仍不充分的构型表示：它以较低关联阶获得了泛型物理可分性，却没有保证严格可分性、碰撞附近的稳定性或有限截断的充分性。

4. 基本关联多项式与递推增强

对单项式

$$m = \prod_{e=1}^M x_e^{a_e},$$

定义代数次数 $\deg(m) = \sum_{e=1}^M a_e$, 以及关联阶 $\text{corr}(m) = |\{e : a_e > 0\}|$. 对于本文由单个单项式轨道求和得到的 PIP, 所有单项式具有相同的关联阶和代数次数, 因此二者均可由其中任意一个单项式确定。

显然 $\text{corr}(m) \leq \deg(m)$. 例如 x_e^{100} 的代数次数为 100, 但关联阶为 1; 而 $x_{e_1}x_{e_2}x_{e_3}$ 的代数次数和关联阶均为 3。我们可以称呼关联阶等于多项式阶的置换不变多项式为基本关联多项式。

回到上述反例三个四原子构型。全部一关联多项式也就是幂和多项式只记录六条边的无标号值分布, 因而不能区分 A, B, C 。而二关联量能够将 C 与 A, B 分开, A 与 B 仍然无法区分。三关联量可以突破这一限制。对于拟合而言, 新增高关联多项式可以进一步区分原有描述符不能区分的构型, 并改拟合条件; 详见 SI 第 S6–S7 节。

我们注意到一个置换不变多项式的计算成本和涉及的单项式数量与关联阶的相关性大于多项式阶。一个高阶低关联的置换不变多项式往往成本更低廉。幂和多项式的构造和计算方法给我们提供了基本的灵感。它的计算流程可以分为3步, 首先选择最廉价的一阶基本关联的多项式。随后不断递推计算 $x_e^{a_e}$, 最后再把 N 阶递推结果带一阶基本关联多项式, 就可以廉价的计算一系列的幂和多项式。我们的工作把类似三步策略一般化, 推广到全体 k 阶基本关联多项式。使用 k 阶基本关联多项式不断递推, 就可以收获大量的高阶多项式。这些高阶多项式加入描述符可以提升可分性, 以及改善势能面的拟合误差。

独立选择各因子的幂次可能破坏置换不变性。例如, 若某个允许的原子置换交换 x_e 与 x_f , 原来的乘积 $x_e x_f$ 不变。但将其替换为 $x_e^p x_f^q$ 后, 交换得到的是 $x_e^q x_f^p$, 当 $p \neq q$ 时二者一般不同。最简单的解决方案是令同类键长使用相同幂次。以单元体系为例, 逐变量递推 $x_e^{n+1} = x_e x_e^n$, 再代入选定的 k 阶基本关联多项式 B :

$$B_n(\vec{x}) = B(x_1^n, \dots, x_M^n), \quad n = 1, \dots, D.$$

多元素体系中, 不同键长类别可独立选择递推次数, 同类键长仍使用相同幂次。这一构造适用于任意 k , 但生成的只是高阶 k -关联多项式的一个子集。同类键长共享幂次的约束也可通过对称化放宽。例如, 将二关联多项式中的每个同类键长乘积 $x_e x_f$ 替换为 $x_e^p x_f^q + x_e^q x_f^p$ ($p, q \geq 1$), 即可在保持置换不变性的同时允许不同幂次。

以最常用的二关联的同幂次递推为例, $M = O(N^2)$ 个键长变量对应至多 $O(N^4)$ 个键长对, 递推至 D 阶并直接求和的求值成本为 $O(N^4 D)$ 。显著的低于高阶 PIP 的计算成本。某种意义上讲我们的此类工作可以视为一种斜线截断策略, 传统的不变量势能面拟合, 使用简单的多项式代数次数截断, 而我们使用代数次数-关联阶数双截断, 越低的关联阶的多项式使用的代数次数越高。

5 基函数变换与角度增强

PIP 通常并不直接以键长为变量, 而是以键长的标量函数为变量, 例如 $1/r$ 、 $\exp(-\alpha r)$ ($\alpha > 0$) 以及高斯型函数等。这些变换同样适用于前述递推构造: 对于一个选定的基本关联多项式, 可以用多种基函数分别初始递推, 再将结果代入同一多项式模板, 合并所得描述符。每组递推中, 同类键长采用相同的基函数与递推次数, 以保持置换不变性。

这一构造也不限于键长。键角、二面角等其他内坐标的标量函数同样可以作为多项式变量; 只要按原子置换进行对称化, 同一单项式中也可以同时涉及不同类型的内坐标。本文进一步以键角和二面角的一阶基本关联多项式为模板, 通过递推构造角向不变量, 补充键长描述符。

具体而言，以键角或二面角的余弦值 $z = \cos \theta$ 或 $\cos \phi$ 为初始变量，采用切比雪夫递推：

$$T_0(z) = 1, \quad T_1(z) = z, \quad T_{n+1}(z) = 2zT_n(z) - T_{n-1}(z), \quad n \geq 1.$$

由 $T_n(\cos \phi) = \cos(n\phi)$ ，可从初始余弦值直接获得高阶角向函数，无需显式计算角度；键角情形同理。随后对对称等价的角度求和，所得多项式仍保持一关联结构，但关于余弦变量的代数次数提高至 n 。若枚举全部角度并递推至 D 阶，键角和二面角部分的求值成本分别为 $O(N^3 D)$ 和 $O(N^4 D)$ ，后者与键长二关联直接求和的同幂次递推上界同阶。具体数值处理及现有程序的实现范围见 SI 第 S10–S12 节。

参考文献提示

1. M. Boutin and G. Kemper, "On Reconstructing n -Point Configurations from the Distribution of Distances or Areas," *Advances in Applied Mathematics* **32**, 709–735 (2004). [arXiv:math/0304192](https://arxiv.org/abs/math/0304192).
2. M. Boutin and G. Kemper, "Which Point Configurations Are Determined by the Distribution of Their Pairwise Distances?" *International Journal of Computational Geometry & Applications* **17**, 31–43 (2007). [arXiv:math/0311004](https://arxiv.org/abs/math/0311004).
3. P. Pyykkö and M. Atsumi, "Molecular Single-Bond Covalent Radii for Elements 1–118," *Chemistry—A European Journal* **15**, 186–197 (2009). DOI: [10.1002/chem.200800987](https://doi.org/10.1002/chem.200800987).

SI

以下证明与结论中，部分是不变量理论中标准结果的重述，部分源于前人的工作；本文不对这些基础性内容作原创性主张。在此列出详细论证，主要是为了帮助读者理解正文相关论述与结论的数学依据、适用条件和推导细节。

S1. 构型域、群作用与术语约定

记 $Q = (\mathbf{q}_1, \dots, \mathbf{q}_N) \in (\mathbb{R}^3)^N$ ， $G \leq S_N$ 为指定的全同原子置换群，并采用

$$(gQ)_i = \mathbf{q}_{g^{-1}(i)}, \quad E_r = \{\{i, j\} : 1 \leq i < j \leq N\}, \quad M = |E_r|.$$

因而距离或同类键上的相同标量变换满足 $x_e(gQ) = x_{g^{-1}e}(Q)$ 。这里“键”指全部原子对距离，不只指由某一平衡构型指定的化学键。若删去部分原子对、使用邻居表或局部截断，则必须另外说明索引集合对 G 的封闭性，本文关于完整距离信息的结论不能直接照搬。

本文针对不受外场等额外条件破坏对称性的标量势能，采用 $E(3) = \mathbb{R}^3 \rtimes O(3)$ ，其中包括反射。完整带标号距离相同的构型具有相同的中心化 Gram 矩阵，因此至多相差平移和正交变换。物理构型空间可表示为

$$\mathcal{Q}/(E(3) \times G) \simeq X_{\text{phys}}/\rho(G), \quad X_{\text{phys}} = \{(r_{ij}(Q))_{i < j} : Q \in \mathcal{Q}\}.$$

这里 $\mathcal{Q}$ 是所研究的、对上述群作用封闭的构型域， $\rho(G)$ 是原子置换在边上的诱导像。纯距离和本文的余弦通道均不区分镜像；若只希望模掉 $SO(3)$ ，或拟合手性敏感的物理量，则需另设具有适当变换性质的有向特征。

下文区分三个不同概念：代数生成整个不变量环；在指定域上分离全部轨道；在除去例外集合后泛型分离轨道。“SFI”表示以轨道分离为目标的构造，不表示每个实际截断都被证明全局可分，也不表示所选描述符彼此代数独立。最小代数生成集完全可能含有代数关系，甲醛例子正是如此。

“多项式”还需注明基本变量： $x_{ij} = e^{-\alpha r_{ij}}$ 上的多项式一般不是 r_{ij} 上的多项式；角度余弦上的多项式也一般不是距离上的多项式。关联阶总是相对于当前指定的基本变量定义，不能把角度变量的一关联直接等同于距离变量的一关联。

S2. 代数完备推出可分性

这是不变量理论中的标准结果，相关概念见 [Kemper, Separating Invariants](#)。设特征为零的域 $\mathbb{K}$ 上有限群 G 线性作用于 $\mathbb{K}^d$ ，相应的不变量环为

$$\mathbb{K}[x]^G = \{h \in \mathbb{K}[x] : h(gx) = h(x), \forall g \in G\}.$$

若有限集合

$$F_{\text{gen}} = \{f_1, \dots, f_L\}$$

满足

$$\mathbb{K}[x]^G = \mathbb{K}[f_1, \dots, f_L],$$

则称其代数生成不变量环。若对给定构型域 X 中任意 x, y ,

$$f_i(x) = f_i(y) \quad (i = 1, \dots, L) \implies y \in Gx,$$

则称 F_{gen} 在 X 上分离 G -轨道。

命题 S1. 对有限群作用，任意代数生成集都是轨道可分集。

证明。 首先证明有限群不变量能够分离任意两个不同轨道。若 $Gx \neq Gy$ ，则 Gx 和 Gy 是两个不相交的有限点集。由于 $\mathbb{K}$ 是无限域，可以选择一个线性函数 ℓ ，使其在有限集合 $Gx \cup Gy$ 的各点上取值互不相同。由单变量 Lagrange 插值，存在多项式 L ，使

$$L(\ell(z)) = \begin{cases} 1, & z \in Gx, \\ 0, & z \in Gy. \end{cases}$$

令 $h = L \circ \ell$ ，并用 Reynolds 算符将其对称化：

$$\mathcal{R}_G h(z) = \frac{1}{|G|} \sum_{g \in G} h(g^{-1}z).$$

$\mathcal{R}_G h$ 是 G -不变多项式，并且在 Gx 上恒为 1、在 Gy 上恒为 0，因此能够区分这两个轨道。

若代数生成集 F_{gen} 不能分离某两个轨道，则存在 $x \not\sim_G y$ 满足 $f_i(x) = f_i(y)$ 。然而任意不变量都可写为

$$h = P(f_1, \dots, f_L),$$

所以所有不变量在 x, y 上均相等，这与上面的轨道分离多项式矛盾。因此

$$\text{代数完备} \implies \text{轨道可分}.$$

逆命题一般不成立。轨道可分只要求描述符映射在商空间 X/G 上为单射，并不要求其他不变多项式能够由该描述符作多项式表达。

S3. 甲醛例子详解

考虑甲醛 CH_2O ，其非平凡置换对称性是两个氢原子的交换。记

$$\begin{aligned} c &= r_{\text{CO}}, & d &= r_{\text{H}_1\text{H}_2}, \\ a &= r_{\text{CH}_1} + r_{\text{CH}_2}, & u &= r_{\text{CH}_1} - r_{\text{CH}_2}, \\ b &= r_{\text{OH}_1} + r_{\text{OH}_2}, & v &= r_{\text{OH}_1} - r_{\text{OH}_2}. \end{aligned}$$

氢交换保持 a, b, c, d 不变, 并使

$$(u, v) \mapsto (-u, -v).$$

因此关于 u, v 的不变量环由 u^2, uv, v^2 生成。作线性组合

$$q = u^2 - v^2, \quad p = 2uv, \quad s = u^2 + v^2,$$

即可得到一组代数完备不变量

$$F_{\text{gen}} = \{a, b, c, d, q, p, s\}.$$

三者满足

$$s^2 = q^2 + p^2.$$

在实变量域上, $s \geq 0$, 故

$$s = \sqrt{q^2 + p^2}.$$

因此,

$$F_{\text{sep}} = \{a, b, c, d, q, p\}$$

的取值唯一确定完整生成集 F_{gen} 的取值。由第 S2 节中代数生成集必然可分的结论, F_{sep} 仍能分离全部实轨道。

最后说明这里的恢复确实不是多项式关系。假设 $s = P(a, b, c, d, q, p)$ 为多项式恒等式。由于 a, b, c, d, u, v 是独立的线性坐标, 令 $a = b = c = d = 0$, 便得到 $s = \tilde{P}(q, p)$ 。比较关于 u, v 的二次齐次项, 必有

$$u^2 + v^2 = \alpha(u^2 - v^2) + 2\beta uv.$$

比较 u^2 和 v^2 的系数, 分别要求 $\alpha = 1$ 和 $-\alpha = 1$, 矛盾。因此 $s \notin \mathbb{R}[a, b, c, d, q, p]$ 。这里的置零是在抽象多项式环中检验恒等式, 并不要求这些零值对应合法分子构型。

上述差别并不是选择了一个非最小生成集造成的。经过可逆线性换元, 完整不变量环可以写为

$$\mathbb{R}[a, b, c, d] \otimes \mathbb{R}[u^2, uv, v^2].$$

其不可分解生成元空间包含四个一次生成元 a, b, c, d 和三个二次生成元 u^2, uv, v^2 。更明确地, 令 A 为该不变量环, $\mathfrak{m}$ 为常数项为零的不变量组成的极大理想, $\mathfrak{m}^2$ 则由这类不变量两两乘积的有限和组成。由于不变量中不存在 u, v 的一次项, 这些乘积均不含上述七个单项式, 而其余非恒定不变单项式均可分解为至少两个常数项为零的不变量的乘积, 因此这七个量的剩余类构成 $\mathfrak{m}/\mathfrak{m}^2$ 的一组基, 其维数为 7。任意代数生成集减去各自的常数项后, 其多项式组合在该商空间中只剩下生成元的线性组合, 故这些生成元的剩余类必须线性张成整个七维空间。因此任何代数生成集都至少含有七个元素, 而 F_{gen} 已经达到这个下界。

另一方面, 非退化四原子距离构型在距离空间中包含六维开集, 除以有限的氢交换后局部维数仍为六。多项式描述符是连续映射; 能够分离全部轨道的连续标量描述符不可能少于六个。 F_{sep} 恰有六个元素, 因此也达到实构型域上的最小可分数目。

S4. 幂和恢复键值无序多重集

设 M 个键长变量或其单射变换为 $x_1, \dots, x_M$, 定义前 M 个幂和

$$p_n(x) = \sum_{i=1}^M x_i^n, \quad n = 1, \dots, M.$$

令 e_k 为第 k 个初等对称多项式并令 $e_0 = 1$ 。Newton 恒等式为

$$k e_k = \sum_{i=1}^k (-1)^{i-1} e_{k-i} p_i, \quad k = 1, \dots, M.$$

因此 $p_1, \dots, p_M$ 依次确定 $e_1, \dots, e_M$, 进而确定首一多项式

$$q_x(t) = t^M - e_1 t^{M-1} + \dots + (-1)^M e_M = \prod_{i=1}^M (t - x_i).$$

q_x 的根及其重数恰好构成无序多重集合 $\{x_1, \dots, x_M\}$ 。若两个无序多重集不同, 则相应首一多项式 q_x, q_y 的根或其重数不同, 二者之差为非零多项式, 因而存在某个实数 t_0 使 $q_x(t_0) \neq q_y(t_0)$ 。若前 M 个幂和全部相等, Newton 恒等式又会使两个多项式的全部系数相同, 与上述取值不同矛盾, 因此至少有一个 $n \leq M$ 满足 $p_n(x) \neq p_n(y)$ 。由此得到

$$(p_1(x), \dots, p_M(x)) = (p_1(y), \dots, p_M(y))$$

当且仅当 x 和 y 只相差某个 S_M 中的变量置换。若只保留 $D < M$ 个幂和, 则上述完整恢复结论一般不再成立。

这一结论也可由代数完备性推出: Newton 恒等式表明 $p_1, \dots, p_M$ 能够多项式地生成全部初等对称多项式, 而后者生成对称多项式环 $\mathbb{R}[x_1, \dots, x_M]^{S_M}$, 因此前 M 个幂和代数完备; 再由第 S2 节的结论, 它们能够分离 S_M 轨道, 即区分不同的无序多重集。

对多元素体系, 将边集分解为一次变量轨道 $E_r = \bigsqcup_{\alpha} E_{\alpha}$, 在每一块计算

$$p_{\alpha,n} = \sum_{e \in E_{\alpha}} x_e^n, \quad 1 \leq n \leq |E_{\alpha}|.$$

这只恢复各块内的多重集, 即分离扩大群 $\prod_{\alpha} S_{E_{\alpha}}$ 的轨道。即便两个块没有共同边变量, 同一个原子交换仍可同时作用于两块, 所以不能独立重排各块再断言全局构型等价。甲醛中的 CH 与 OH 两块就是这一同步作用的例子, 混合量 uv 记录了纯块统计缺失的配对信息。

S5. 物理距离域上的泛型构型重构

设 Δ 为实对称、对角元为零的平方距离候选矩阵, 非对角元取非负值:

$$\Delta_{ij} = r_{ij}^2.$$

令

$$J = I - \frac{1}{N} \mathbf{1} \mathbf{1}^T, \quad B = -\frac{1}{2} J \Delta J.$$

Δ 是某个三维欧氏构型的距离矩阵, 当且仅当

$$B \succeq 0, \quad \text{rank}(B) \leq 3.$$

必要性来自中心化坐标矩阵 Y 满足 $B = YY^T$ 。反过来，对半正定且秩不超过 3 的 B 作特征值分解，可取至多三列的 Y 使 $B = YY^T$ ；由 Δ 对称且对角为零，有 $\Delta_{ij} = B_{ii} + B_{jj} - 2B_{ij}$ ，因此 Y 各行间的平方距离正好恢复 Δ 。排除原子重合时再要求 $r_{ij} > 0$ 。

因此，除去整体平移与转动后，一般三维构型的自由度为 $3N - 6$ ，而抽象边空间的维数为

$$M = \binom{N}{2}.$$

两者的维数差为

$$M - (3N - 6) = \frac{(N - 3)(N - 4)}{2}.$$

当 $N = 4$ 时该差为零，非退化合法距离在局部不存在额外的等式型余维约束，尽管仍须满足三角不等式和半正定性等不等式条件；当 $N \geq 5$ 时，秩条件和 Cayley--Menger 关系开始以等式形式限制任意的边值重排。

这里采用代数几何意义下的“一般位置”或“泛型”概念：若某一性质在除去一个真代数集合之后成立，则称它泛型成立。Boutin 和 Kemper 的重构结果表明，对于 $N \geq m + 2$ 个位于 $\mathbb{R}^m$ 中的一般位置点，全部无标号两两距离唯一确定该点构型，允许相差欧氏等距变换和点的重标号。等价地，存在一个非零多项式 $F(Q)$ ，使得

$$F(Q) \neq 0$$

时构型可以从距离分布中重构。定理未覆盖的构型包含在真代数集合 $F(Q) = 0$ 中。该集合在 $\mathbb{R}^{mN}$ 中具有 Lebesgue 零测度。因此，只要构型采样分布相对于 Lebesgue 测度具有连续密度，采中例外集合的概率为零。

对三维全同原子体系， $m = 3$ ，所以

$$N \geq 5 \implies \text{完整距离多重集合泛型确定构型轨道}.$$

若径向变换 $u(r)$ 为单射，则 $\{u(r_{ij})\}$ 和 $\{r_{ij}\}$ 含有相同信息。结合上一节的 Newton 恒等式可知，前 M 个完整幂和对 $N \geq 5$ 的三维全同原子体系具有泛型轨道可分性。

该结论具有以下限制：

1. 它是泛型而非全局结论，不能排除特殊构型上的严格碰撞。
2. 它不适用于三维 $N = 4$ 的情形，第 S6 节给出物理反例。
3. 它要求完整恢复距离多重集合，不能直接推广到只取 $D < M$ 个低阶矩的有限截断。
4. 对多元素体系，允许的原子重标号群通常是 $S_{N_1} \times \cdots \times S_{N_s}$ 而不是 S_N ；需要按照元素类型构造相应的变量轨道，不能直接套用全同点的无标号距离结论。
5. 零测度只描述严格碰撞的概率，不保证例外集合附近的逆映射具有良好条件数。近碰撞仍可能影响势能拟合。

这里引用的是 Boutin 和 Kemper 的 Theorem 1.6，而不是由自由度计数推导出的可分性定理。原文使用平方距离；在非负距离域上平方映射为单射，因此与距离多重集等价。例外代数集合是实际不可重构集合的一个包含集，而非其精确刻画：落入该集合并不必然不可重构，也不能把不可重构与“高对称”视为同义词。

若采样被严格约束在平面、固定键长流形或某条反应路径上，它相对于全笛卡尔空间的 Lebesgue 测度通常是奇异的。此时需要判断例外集合与实际采样支撑的交集，不能直接援引上述概率为零的结论。近碰撞则不受“恰好命中例外集合的概率为零”保护。

S6. 四原子反例及关联层次的显式验证

S6.1 边值分配与三维可实现性

沿用正文的编号，在边顺序 (12, 13, 14, 23, 24, 34) 下，三个距离向量为

$$r_A = (a, a, a, b, b, b), \quad r_B = (a, a, b, a, b, b), \quad r_C = (a, b, b, a, b, a).$$

由 a 边构成的图分别为星形、三角形加孤立点和三边路径，度数序列分别为 $(3, 1, 1, 1)$ 、 $(2, 2, 2, 0)$ 和 $(2, 2, 1, 1)$ 。当 $a \neq b$ 时，该图必须被任何保持距离的原子重标号保持，因此三者两两不等价。

令 $a = \sqrt{2}$, $b = 1$ ，由 $B_X = -J\Delta_X J/2$ 直接计算得

$$\begin{aligned} \text{spec}(B_A) &= \left\{ 0, \frac{1}{2}, \frac{1}{2}, \frac{5}{4} \right\}, \\ \text{spec}(B_B) &= \left\{ 0, \frac{1}{4}, 1, 1 \right\}, \\ \text{spec}(B_C) &= \left\{ 0, \frac{3}{4}, \frac{3-\sqrt{5}}{4}, \frac{3+\sqrt{5}}{4} \right\}. \end{aligned}$$

三者均有三个正特征值，故都对应非退化三维四面体。若需生成笛卡尔坐标，取正特征值分解 $B_X = U_+ \Lambda_+ U_+^\top$ ，则 $U_+ \Lambda_+^{1/2}$ 的四行即是一组中心化坐标。任意正数 a, b 并不都能同时实现这三种构型；上述具体取值足以构成物理反例。

S6.2 所有二关联递推仍不能区分星形与三角形

四个全同原子的互异边对只有两类轨道：共享一个端点的相邻边对，以及没有公共端点的不相交边对。下表按**无序边对**计数， (a, b) 包括两种取值顺序。

构型	相邻 (a, a)	相邻 (a, b)	相邻 (b, b)	不相交 (a, a)	不相交 (a, b)	不相交 (b, b)
A: 星形	3	6	3	0	3	0
B: 三角形	3	6	3	0	3	0
C: 路径	2	8	2	1	1	1

每行共有 $12 + 3 = \binom{6}{2}$ 对。定义

$$Q_{\text{adj}} = \sum_{\substack{\{e,f\} \\ |e \cap f|=1}} x_e x_f, \quad Q_{\text{opp}} = \sum_{\substack{\{e,f\} \\ e \cap f = \emptyset}} x_e x_f.$$

在本小节先取 $x_e = r_e$ ，则

$$\begin{aligned} Q_{\text{adj}}(A) &= Q_{\text{adj}}(B) = 3a^2 + 6ab + 3b^2, \\ Q_{\text{adj}}(C) &= 2a^2 + 8ab + 2b^2, \\ Q_{\text{opp}}(A) &= Q_{\text{opp}}(B) = 3ab, \\ Q_{\text{opp}}(C) &= a^2 + ab + b^2. \end{aligned}$$

所以 $Q_{\text{adj}}(A) - Q_{\text{adj}}(C) = (a - b)^2 \neq 0$ ，二关联能够区分 C 与另外两者。

若改用有序边对，表中同值对计数加倍，混合值对分成 (a, b) 与 (b, a) ； A, B 的统计仍逐项相同。因此对任意二元函数 ψ ，以及任一相邻或不相交的有序边对轨道 $\mathcal{O}$ ，都有

$$\sum_{(e,f) \in \mathcal{O}} \psi(r_e(A), r_f(A)) = \sum_{(e,f) \in \mathcal{O}} \psi(r_e(B), r_f(B)).$$

特别地，取 $\psi(s, t) = s^p t^q$ ，或使用任意逐键基函数及其乘积，均不能打破 A, B 的碰撞。任意一关联项也相同，故任意数量的一关联与二关联轨道和，以及它们的确定性后处理，仍不足以分离这两个构型。这是固定关联阶的局限，而不是递推深度不足。

S6.3 一个三关联量即可打破剩余碰撞

三角形轨道和为

$$T_{\Delta}(x) = \sum_{1 \leq i < j < k \leq 4} x_{ij} x_{ik} x_{jk}.$$

直接代入得

$$\begin{aligned} T_{\Delta}(A) &= b^3 + 3a^2b, \\ T_{\Delta}(B) &= a^3 + 3ab^2, & T_{\Delta}(A) - T_{\Delta}(B) &= (b - a)^3. \\ T_{\Delta}(C) &= 2a^2b + 2ab^2, \end{aligned}$$

故 $(Q_{\text{adj}}, T_{\Delta})$ 足以区分这三个例子。若使用单射键长变换 $x = u(r)$ ，只需将上述关联量中的 a, b 换成 $u(a), u(b)$ ，区分结论不变。这只证明给定构型对被区分，不能据此声称三关联已分离全部四原子构型。

S6.4 键角余弦也能携带缺失的联合信息

以每个原子为中心、端点无序枚举全部 12 个键角，定义 $A_1 = \sum \cos \theta$ 。对三角形三边为 (a, a, b) 和 (a, b, b) 的情形，三内角余弦之和分别为

$$s_{aab} = 1 - \frac{b^2}{2a^2} + \frac{b}{a}, \quad s_{abb} = 1 - \frac{a^2}{2b^2} + \frac{a}{b}.$$

三个四面体分别包含“一张 bbb 面加三张 aab 面”、“一张 aaa 面加三张 abb 面”和“两张 aab 面加两张 abb 面”。所以在 $a = \sqrt{2}, b = 1$ 时，

$$A_1(A) = \frac{15}{4} + \frac{3}{\sqrt{2}}, \quad A_1(B) = \frac{3}{2} + 3\sqrt{2}, \quad A_1(C) = \frac{3}{2} + 3\sqrt{2}.$$

一阶角度余弦和已经区分 A, B ，但仍不能区分 B, C 。再取 $A_2 = \sum T_2(\cos \theta)$ ，利用 $T_2(z) = 2z^2 - 1$ 可得

$$A_2(A) = -\frac{45}{8}, \quad A_2(B) = -\frac{9}{2}, \quad A_2(C) = -\frac{19}{4}.$$

这给出了角向一关联递推增强的显式例子：这里的“一关联”是对角度变量而言，单个角度本身已联合依赖一个三原子子构型中的三条距离。

S7. 轨道可分、连续能量表示与数值稳定性

S7.1 可分性何时足以支持连续势能表示

设 X 是物理距离域中的紧致、 G -不变子集， $V : X \rightarrow \mathbb{R}$ 连续且 G -不变， $\Phi : X \rightarrow \mathbb{R}^W$ 连续且轨道可分。它诱导连续双射

$$\overline{\Phi} : X/G \longrightarrow \Phi(X).$$

X/G 紧致而 $\Phi(X)$ 是 Hausdorff 空间，故该双射为同胚。因此存在唯一的连续函数

$$v = \overline{V} \circ \overline{\Phi}^{-1}, \quad V = v \circ \Phi.$$

这说明在紧致工作域上，连续轨道可分能够排除连续能量表示的信息缺失，不要求代数生成全部不变量。但上述论证不保证 v 可微或具有小导数，也不保证某个固定规模神经网络的逼近误差。对非紧致的全域问题，需要另行控制无穷远行为或给出适当的嵌入条件。

S7.2 碰撞造成的误差下界

若 $\Phi(A) = \Phi(B)$ 而 $\delta = |V(A) - V(B)| > 0$ ，任何仅依赖 Φ 的确定性模型在两点给出同一个值，因此

$$\max\{|\widehat{V}(A) - V(A)|, |\widehat{V}(B) - V(B)|\} \geq \frac{\delta}{2}.$$

对近碰撞，若回归函数 v 在相关特征域内具有 Lipschitz 常数 L_v ，令 $\varepsilon = \|\Phi(A) - \Phi(B)\|$ ，则三角不等式给出

$$\max\{|\widehat{V}(A) - V(A)|, |\widehat{V}(B) - V(B)|\} \geq \frac{1}{2} \max\{0, \delta - L_v \varepsilon\}.$$

这解释了模型为何可能在近碰撞区域需要很大的特征空间斜率。此处不声称四原子例子具有某个已计算的能量差；不等价构型可以偶然等能。对一个特定势能而言，必要条件只是能量在每个描述符纤维上为常数，轨道可分是更强、且不依赖具体势能的充分设计目标。

S7.3 新特征只保证碰撞集合不增

定义非等价碰撞对集合

$$\mathcal{C}_\Phi = \{(x, y) \in X^2 : x \not\sim_G y, \Phi(x) = \Phi(y)\}.$$

将新增描述符 Ψ 与原向量拼接，得到

$$\mathcal{C}_{(\Phi, \Psi)} = \mathcal{C}_\Phi \cap \{(x, y) : \Psi(x) = \Psi(y)\} \subseteq \mathcal{C}_\Phi.$$

包含可以是等号；即便为真包含，维数也不一定严格下降。因此更高关联提供了消除碰撞的机会，而不是必然逐阶降维的定理。对已经聚合的 Φ 计算 $h(\Phi)$ 不会增强可分性，逐变量递推后再聚合则可能产生不由原向量决定的新特征。

最后，局部信息还取决于物理切空间上的 Jacobian。若存在非零物理方向 w 满足 $D\Phi w = 0$ ，则任何可微模型 $v \circ \Phi$ 在该方向的导数均为零；若真实势能的方向导数非零，力便不能被准确表示。评估条件数时应先去除平移、转动等必然零模，并固定特征尺度；严格轨道可分本身不保证 Jacobian 处处满秩。

S8. 基本关联模板与一般递推构造

S8.1 平方自由模板和有序轨道的区别

对互异边组成的支撑 $S = \{e_1, \dots, e_k\}$ ，定义基本关联模板

$$B_{[S]}(x) = \sum_{S' \in G \cdot S} \prod_{e \in S'} x_e.$$

轨道中相同支撑只计一次，每个单项式均为平方自由单项式，因而关联阶与代数次数同为 k 。该模板不是“最小代数生成元”的同义词：基本关联模板也可能代数冗余。模板可通过群生成元在 k 元支撑集合上的连通分量求得，随后提高递推深度时无需重新枚举高总次数的单项式空间。

同类变量采用相同基函数时，逐变量代入直接给出不变量

$$B_{[S],n}(Q) = B_{[S]}(\phi_n(z_1(Q)), \dots, \phi_n(z_M(Q))).$$

若 $\phi_n(z) = z^n$ ，该量恰有代数次数 kn 、关联阶 k 。若 ϕ_n 含低次项或常数项，则展开后可以含低关联项，只能保证最高关联阶不超过 k 、最高次数不超过 kn 。

对于不同幂次，不能任意给无序支撑中的因子指定序号。可以转而使用下述有序元组轨道；它保留不同指数与不同结构角色的对应关系。同类二边可交换时，等价写法是对无序边对使用 $x_e^p x_f^q + x_e^q x_f^p$ 。在 $p = q$ 时，该写法比无序支撑模板多一个因子 2。固定非零常数不影响可分性，但会影响输出数值与标准化，必须保持同一计数约定。

S8.2 一般有序轨道聚合及其不变性

设 E 为基本变量的索引集合，有限置换群 G 在 E 上作用。对由 k 个互异索引组成的有序元组

$$\mathbf{e} = (e_1, \dots, e_k),$$

记其轨道为 $\mathcal{O} \subset E^k$ 。在每个基本变量 z_e 上计算单变量递推基

$$\phi_0(z_e), \phi_1(z_e), \dots, \phi_D(z_e).$$

对多重指标 $\boldsymbol{\nu} = (\nu_1, \dots, \nu_k)$ 定义

$$C_{\mathcal{O};\boldsymbol{\nu}}(Q) = \sum_{(e_1, \dots, e_k) \in \mathcal{O}} \prod_{j=1}^k \phi_{\nu_j}(z_{e_j}(Q)).$$

若基本变量满足

$$z_e(gQ) = z_{g^{-1}e}(Q),$$

则对任意 $g \in G$,

$$\begin{aligned} C_{\mathcal{O};\boldsymbol{\nu}}(gQ) &= \sum_{\mathbf{e} \in \mathcal{O}} \prod_{j=1}^k \phi_{\nu_j}(z_{g^{-1}e_j}(Q)) \\ &= \sum_{\mathbf{e}' \in g^{-1}\mathcal{O}} \prod_{j=1}^k \phi_{\nu_j}(z_{e'_j}(Q)) \\ &= C_{\mathcal{O};\boldsymbol{\nu}}(Q), \end{aligned}$$

其中最后一步使用了 $g^{-1}\mathcal{O} = \mathcal{O}$ 。因此任意关联阶和任意递推深度下，该轨道聚合都严格满足指定的置换不变性。

多元素或多种内坐标的情形可为每个一次变量轨道指定不同的基函数族。只要轨道标签 $\alpha(e)$ 满足 $\alpha(ge) = \alpha(e)$ ，将上式中的 ϕ_{ν_j} 换成 $\phi_{\alpha(e_j), \nu_j}$ ，证明仍然成立。所谓“不同类别独立选择递推次数”仅指参数选择，不表

示这些类别的原子置换作用彼此独立。

S8.3 单变量递推及换基的适用范围

最直接的单变量递推是幂基

$$\phi_0(z) = 1, \quad \phi_1(z) = z, \quad \phi_{n+1}(z) = z\phi_n(z).$$

若先将 z 变换到 $[-1, 1]$, 还可以使用 Chebyshev 递推

$$T_0(z) = 1, \quad T_1(z) = z, \quad T_{n+1}(z) = 2zT_n(z) - T_{n-1}(z),$$

或 Legendre 递推

$$P_0(z) = 1, \quad P_1(z) = z, \\ P_{n+1}(z) = \frac{(2n+1)zP_n(z) - nP_{n-1}(z)}{n+1}.$$

由于 T_n 和 P_n 都是具有非零最高次项的 n 次多项式, 从

$$\{1, z, \dots, z^D\}$$

到

$$\{T_0, \dots, T_D\} \quad \text{或} \quad \{P_0, \dots, P_D\}$$

的换基矩阵为可逆三角矩阵。因此在相同最高次数 D 下, 三种基张成相同的单变量多项式空间; 换用正交多项式改变的是数值条件和特征组合, 而不是该截断空间的代数信息容量。

这里的等价首先是**单变量空间的等价**。对一关联求和, 连同已知常数通道, 该三角换基直接保留前 D 阶矩的信息; 对 k -关联张量积, 只有保留的多重指标集合在逐分量降低次数下封闭时, 才可同样推出换基前后的聚合空间相同, 例如包含零阶的完整盒形截断 $0 \leq \nu_j \leq D$ 。

仅保留对角指标 $(n, \dots, n)$ 时, 这一推论一般不成立。例如

$$T_3(x)T_3(y) = 16x^3y^3 - 12(x^3y + xy^3) + 9xy$$

包含同幂次幂基模板没有直接提供的 $(3, 1)$ 混合项。因此同幂次方案换用 Chebyshev 基后可能改变有限描述符集合的区分能力, 不能只称为无损线性换基。多种径向映射并用时也应按实际截断重新评估, 而非把单变量等价性推广到任意稀疏集合。

S9. 双截断、求值复杂度与存储

S9.1 截断集合的明确指定

令 $\mathcal{T}_k$ 为保留的 k -关联模板集合, $\Lambda_{k,\mathcal{O}}$ 为每个轨道保留的递推多重指标集合, 描述符由

$$\mathcal{S} = \{(\mathcal{O}, \boldsymbol{\nu}) : 1 \leq k \leq K, \quad \mathcal{O} \in \mathcal{T}_k, \quad \boldsymbol{\nu} \in \Lambda_{k,\mathcal{O}}\}$$

完全指定。对幂基, 可分别使用同幂次截断 $\boldsymbol{\nu} = (n, \dots, n)$ 、按变量类别共享指数的截断, 或完整混合指数截断。三者不是同一个模型; 仅报告 K, D 不足以唯一重建描述符。

正文的“斜线截断”可用随关联阶变化的总次数预算 P_k 表述:

$$\text{corr}(m) = k \leq K, \quad \text{deg}(m) \leq P_k.$$

低关联可分配更大的 P_k ；对同幂次幂基，递推深度为 $D_k = \lfloor P_k/k \rfloor$ 。如果直接指定 D_k ，则相应最高总次数为 kD_k ，所以“低关联使用更高代数次数”应检查 kD_k 而不只是 D_k 的大小。该预算是可选设计原则，并非可分性定理。

S9.2 一般成本与几何枚举

若基本变量数为 L ，预计算全部深度不超过 D 的单变量递推量需要

$$O(LD)$$

次基本运算。对选定描述符集合 $\mathcal{S}$ ，直接轨道聚合的额外成本为

$$O\left(\sum_{(\mathcal{O}, \nu) \in \mathcal{S}} k|\mathcal{O}|\right).$$

如果在固定关联阶 k 下保留所有满足 $1 \leq \nu_j \leq D$ 的多重指标，其数量仍可达到 $O(D^k)$ 。因此递推减少了重复生成和求值高次单项式的成本，但没有消除随关联阶产生的组合增长；实际算法仍需同时截断关联阶和递推深度。

更具体地，若固定一个支撑图有 v 个不同原子顶点，其直接嵌入枚举至多为 $O(N^v)$ ，而 k 条边满足 $v \leq 2k$ 。相邻二边只涉及三个原子，不相交二边涉及四个原子，因此二者直接枚举分别为 $O(N^3)$ 和 $O(N^4)$ 。关联阶给出的是粗上界，实际成本还取决于支撑拓扑、元素类型、轨道长度和公共中间量复用。

对固定数目的基函数族，常见直接求值上界如下。 D 为每个单变量的最大递推深度；表中的多重指标均按所注明方式选取。

通道	单阶几何或支撑数	递推和聚合成本
距离一关联	$M_r = \binom{N}{2}$	$O(N^2 D)$
相邻二边，同幂次	$N \binom{N-1}{2}$	$O(N^3 D)$
全部二边，同幂次	$\binom{M_r}{2}$	$O(N^4 D)$
全部二边，完整混合指数	$O(N^4)$	$O(N^4 D^2)$
键角一关联	$M_\theta = N \binom{N-1}{2}$	$O(N^3 D)$
无向二面角一关联	$M_\phi = \binom{N}{2} \binom{N-2}{2}$	$O(N^4 D)$

同幂次模板每个产生 D 个通道；若一个模板包含 t 个变量类别且各类别指数独立，则最多产生 D^t 个通道；完整 k 个位置独立选指数则最多产生 D^k 个通道。这些上界尚未扣除可重复或线性相关的特征。

S9.3 流式递推与训练内存

单变量幂基只需保留当前阶，三项递推只需相邻两阶。同幂次方案因此可在每一阶即时聚合，以 $O(L)$ 递推工作区生成全部输出；保存输出另需 $O(W)$ 空间，模板索引也需单独存储。完整混合指数通常需缓存 $O(LD)$ 的递推表或付出重算成本。反向自动微分保存计算图时可能占用与总运算数相关的内存，不能直接沿用前向流式计算的 $O(L)$ 结论。

S10. 径向映射、归一化与高阶条件数

S10.1 无量纲径向变量

一种与现有一阶正交递推程序一致的选择是先定义

$$\rho_{ij} = \frac{r_{ij}}{\ell_{ij}}, \quad \ell_{ij} = R_i^{\text{cov}} + R_j^{\text{cov}},$$

其中同元素使用相同共价半径，距离与半径必须采用相同长度单位。现有半径表以 Å 为单位，来源为 [Pyykkö](#) 和 [Atsumi](#) 的[单键共价半径表](#)。这一步是尺度选择，不是判定化学成键。

可选映射及其对 ρ 的导数为

$$\begin{aligned} z_{\text{rat}}(\rho) &= \frac{\rho - m}{\rho + m}, & z'_{\text{rat}}(\rho) &= \frac{2m}{(\rho + m)^2}, & m > 0, \\ z_{\text{M}}(\rho) &= 2e^{-a\rho} - 1, & z'_{\text{M}}(\rho) &= -2ae^{-a\rho}, & a > 0, \\ z_{\text{G}}(\rho) &= 2e^{-b(\rho-c)^2} - 1, & z'_{\text{G}}(\rho) &= -4b(\rho - c)e^{-b(\rho-c)^2}, & b > 0. \end{aligned}$$

在 $\rho > 0$ 上，有理和 Morse 映射光滑单射且有界；当 $c > 0$ 且工作域跨越中心 c 时，Gaussian 非单射，因此在这样的域上单个 Gaussian 通道不能承担无损径向编码。若工作域完全位于中心一侧，则应按该实际域重新判断单射性。对键长求导时还需乘以 $1/\ell_{ij}$ 。尺度和映射参数应固定，并对允许置换的同类变量相同；按原子编号任意分配不同参数会破坏置换不变性。

对于有限已知距离区间也可用仿射映射到 $[-1, 1]$ ，但不应把区间外的真实输入硬截到端点来声称全域单射。Morse 和有理映射虽对有限距离单射，在无穷远会压缩距离差异；这种有界性既不保证长程分辨率，也不自动施加正确的解离能、渐近幂律或分片能量可加性。

S10.2 开根、对数与极值支配

对正变量 $x_i > 0$ ，定义

$$R_n = \left(\frac{1}{M} \sum_i x_i^n \right)^{1/n}, \quad L_n = \frac{1}{n} \log \left(\frac{1}{M} \sum_i x_i^n \right) = \log R_n.$$

固定 M, n 时两者与幂和可逆等价。令 $y_i = \log x_i$ ，对数形式可用 log-sum-exp 计算以避免先形成高次幂；但两者都满足

$$R_n \longrightarrow \max_i x_i, \quad \frac{\partial L_n}{\partial x_j} = \frac{x_j^{n-1}}{\sum_i x_i^n}.$$

非最大项的相对贡献随 n 指数衰减，因此开根和取对数主要控制尺度，不能恢复已经低于浮点或模型分辨率的贡献。这些正变量公式不能直接用于可正可负的角度余弦和；对有符号通道任意取绝对值或偶次根可能进一步丢失信息。

S10.3 有界正交递推的收益和局限

在 $z \in [-1, 1]$ 上， $|T_n(z)| \leq 1$ 、 $|P_n(z)| \leq 1$ ；对某一次变量轨道 E_α 的平均矩，有

$$\left| \frac{1}{|E_\alpha|} \sum_{e \in E_\alpha} T_n(z_e) \right| \leq 1,$$

Legendre 基同理。相关标准恒等式见 [NIST DLMF, 第 18 章](#)。求和后的特征可再使用仅由训练集估计并固定的均值与正尺度作逐通道标准化；固定非零尺度不改变精确可分性，但会改变数值分离间隔。训练集上方差为零不代表该通道在整个构型域上恒定，删除通道需单独说明。

幅值有界并不等于逆映射条件良好。完整幂和映射的 Jacobian 为

$$(J_p)_{ni} = nx_i^{n-1}, \quad \det J_p = M! \prod_{i < j} (x_j - x_i).$$

这是 Vandermonde 行列式；键值接近时逆恢复可能病态，键值重复时该带标号 Jacobian 降秩，尽管无序多重集仍由完整矩唯一确定。非奇异线性换基不能消除这种精确秩亏。另一方面， $T'_n(z) = nU_{n-1}(z)$ ，在端点 $|T'_n(\pm 1)| = n^2$ ，高频递推仍可放大输入误差和力的敏感性。正交性是相对于特定单变量权重而言，也不保证实际训练集的聚合特征彼此统计正交。

因此正交递推提供了避免高次幂指数动态范围的方案，不提供对全部构型、全部尺度或全部截断均更优的条件数保证。实际需同时检查误差、特征协方差、物理方向 Jacobian 和近碰撞样本。

S11. 角度变量、置换索引与退化几何

S11.1 键角余弦

对三个互异原子，以 j 为中心、 $\{i, k\}$ 为无序端点对，令

$$\mathbf{a} = \mathbf{q}_i - \mathbf{q}_j, \quad \mathbf{b} = \mathbf{q}_k - \mathbf{q}_j, \quad z_\theta(j; \{i, k\}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \frac{r_{ij}^2 + r_{jk}^2 - r_{ik}^2}{2r_{ij}r_{jk}}.$$

中心与端点角色不能互换；共有 $N \binom{N-1}{2}$ 个变量。对原子重标号后，应保持中心角色并将端点重新排序，按实际群作用构造变量轨道。余弦在两条中心键非零时是光滑函数，包括共线的 $z_\theta = \pm 1$ 情形；直接计算 $T_n(z_\theta)$ 避免引入 $\arccos$ 在端点的表观奇异性。它依然不在零键长处有定义。

S11.2 无向二面角余弦及符号约定

采用与现有程序一致的索引 $(\{j, k\}; \{i, l\})$ ：无序中心边 $\{j, k\}$ 与无序端点对 $\{i, l\}$ 不互换，四个原子互异。计算时取 $j < k, i < l$ ，令

$$\mathbf{c} = \mathbf{q}_k - \mathbf{q}_j, \quad \mathbf{a} = \mathbf{q}_i - \mathbf{q}_j, \quad \mathbf{b} = \mathbf{q}_l - \mathbf{q}_j, \\ \mathbf{n}_i = \mathbf{a} \times \mathbf{c}, \quad \mathbf{n}_l = \mathbf{b} \times \mathbf{c}, \quad z_\phi(\{j, k\}; \{i, l\}) = \frac{\mathbf{n}_i \cdot \mathbf{n}_l}{\|\mathbf{n}_i\| \|\mathbf{n}_l\|}.$$

交换 i, l 只交换两个法向量；交换 j, k 则两个法向量同时变号，因此 z_ϕ 不变。由此上述无序索引与函数值相容，变量数为

$$M_\phi = \binom{N}{2} \binom{N-2}{2} = 6 \binom{N}{4}.$$

这一定义的零角对应两个端点在中心轴的同侧半平面内。若另一程序以有向链 $i - j - k - l$ 定义 $\mathbf{b}_1 = \mathbf{q}_j - \mathbf{q}_i$ 、 $\mathbf{b}_2 = \mathbf{q}_k - \mathbf{q}_j$ 、 $\mathbf{b}_3 = \mathbf{q}_l - \mathbf{q}_k$ ，并用 $(\mathbf{b}_1 \times \mathbf{b}_2) \cdot (\mathbf{b}_2 \times \mathbf{b}_3)$ 归一化，则两个法向量分别为 $-\mathbf{n}_i, -\mathbf{n}_l$ ，余弦与这里相同。若只把其中一个叉乘的顺序反转，余弦才会变号，相应奇数阶 Chebyshev 通道变号而偶数阶不变；迁移参数或对比输出时必须统一约定。

由向量恒等式也有

$$z_\phi = \frac{(\mathbf{a} \cdot \mathbf{b})\|\mathbf{c}\|^2 - (\mathbf{a} \cdot \mathbf{c})(\mathbf{b} \cdot \mathbf{c})}{\sqrt{\|\mathbf{a}\|^2\|\mathbf{c}\|^2 - (\mathbf{a} \cdot \mathbf{c})^2}\sqrt{\|\mathbf{b}\|^2\|\mathbf{c}\|^2 - (\mathbf{b} \cdot \mathbf{c})^2}}.$$

其中 $\mathbf{a} \cdot \mathbf{b} = (r_{ij}^2 + r_{jl}^2 - r_{il}^2)/2$ ，其余点积同理，故单个二面角一般联合依赖六条距离。这不是“关于距离的六阶多项式”：表达式还含除法与平方根，距离关联阶不能直接按六条距离机械赋予某个多项式次数。

S11.3 轨道聚合与退化点

对键角或二面角变量的一次轨道 $E_{\gamma,\alpha}$ ，定义

$$F_{\gamma,\alpha,n}(Q) = \sum_{e \in E_{\gamma,\alpha}} T_n(z_\gamma(e; Q)), \quad \gamma \in \{\theta, \phi\}.$$

这些变量满足第 S8 节的置换协变关系，所以聚合严格不变。多元素体系必须保留中心/端点的类型与角色；不能只按三原子或四原子的无序元素组成随意合并轨道。合并完整轨道仍不变，但可能丢失区分信息。

二面角在任一法向量为零时不定义，其邻近极限依赖接近路径。当前数据转换代码对零中心键或零法向量约定 $z_\phi = 1$ ，对零键长的键角也约定 $z_\theta = 1$ ；这只是退化输入的数值占位，不是光滑物理延拓。合法的线性构型本身也可能包含退化二面角，因此“属于物理域”并不足以排除问题。

若用于力学习或动力学，必须明确选择：限制研究域使相关分母远离零；或者采用重新定义的光滑特征，并据此重新验证。一个可检验的替代量为

$$\tilde{z}_\phi = \frac{\mathbf{n}_i \cdot \mathbf{n}_l}{\sqrt{\|\mathbf{n}_i\|^2 + \epsilon^2}\sqrt{\|\mathbf{n}_l\|^2 + \epsilon^2}}, \quad \epsilon > 0.$$

它保持索引对称性且光滑有界，但已不等于严格二面角余弦，故 $T_n(\tilde{z}_\phi)$ 不能再解释为原二面角的 $\cos(n\phi)$ 。 ϵ 与法向量同量纲，即长度平方，应固定且在置换等价索引上相同；该式只是替代方案，不表示当前代码已经采用。对于余弦计算的极小舍入越界可作数值保护，但大幅越界必须诊断，不能用硬截断掩盖退化或实现错误。

S12. 实现范围、验证标准与复现实验信息

S12.1 一般方法与当前程序入口

以下区分随稿程序中已存在的描述符计算路径与理论可扩展范围，避免将不同入口合并为一套已完成验证的实现。

项目	SFI 入口	SFI_v02 入口
径向模板	从输入 FI 中按次数和平方自由条件筛选，按一次变量类别共享函数及递推指数	仅使用输入 FI 中的一阶轨道
径向函数	支持已配置的幂、倒数、指数等函数族	共价半径无量纲化后的 rational、Morse、Gaussian 映射
角向通道	XYZ 上计算余弦，再作 Chebyshev 递推和所选模板聚合	XYZ 上的一阶角向轨道，Chebyshev 或 Legendre 递推
输出	描述符矩阵；C/Fortran 代码生成目前只覆盖径向 SFI	描述符矩阵及逐列元数据，不提供代码生成

从 FI 文件筛选平方自由模板，不等于已经枚举全部基本关联轨道；理论定义允许的模板比某份 FI 文件的子集更广。复现实验时必须保存实际模板文件，不能只报告“使用二阶 FI”。

SFI_v02 按通道、轨道、递推次数排列特征，直接输出轨道和，未自动除以轨道长度；列元数据记录对应轨道大小和次数。第 S10 节的平均化与训练集标准化是可选后处理，应注明是否实际采用。它采用相邻两阶的流式递推，并在轨道求和中使用补偿累加；这些做法减少计算开销或舍入误差，但不提供新的精确可分性。

第 S11.3 节的光滑退化处理，应与已采用的实现分别报告。不能仅因它在数学上可行就写为已经用于所报告实验。

S12.2 严格可分性与数值检验的证据等级

若要声称某个有限描述符集在指定物理域 X 上全局可分，必须证明不存在

$$x, y \in X : \quad \Phi(x) = \Phi(y), \quad \|y - \rho(g)x\|^2 > 0 \quad \text{对全部 } g \in G$$

的解。对于在所选变量上为多项式、且域约束为半代数条件的问题，可使用实代数方法寻求无解证书。对复代数域的根理想证书和对实物理域的证书必须区分，甲醛例子说明这种区分是实质性的；含指数映射时也不能未经处理就把全部约束当成多项式系统。

随机采样、优化搜索或有限数据集上未发现碰撞，只能提供经验检验，不能构成上述无解证明。反之，找到描述符相同且物理不等价的一对构型就足以否定全局可分性。数值近碰撞需要报告特征标准化、比较容差和构型不等价的判断方式；不能把距离向量的普通排序相等误当成原子置换等价。

S12.3 拟合与成本比较需补充的信息

理论部分不预设拟合实验的结果。正式报告某个 SFI 势能面时，应为每个体系列明以下信息，并区分已运行的实验与拟议测试：

- 数据与目标：**原子组成、允许置换群、电子态与参考计算方法、能量和长度单位、构型/能量覆盖范围，以及训练、验证、测试集划分。来自同一轨迹的近邻帧需注意数据泄漏。
- 描述符配置：**实际模板和变量索引文件、关联阶、各模板的递推指标、径向映射及参数、角向符号约定、归一化、最终通道数、退化构型处理方式。用于力计算时还应记录分母阈值或正则化参数及其单位。
- 模型与训练：**网络结构和激活函数、参数量、优化器、随机种子、训练停止条件；若同时拟合力，需报告能量/力损失的定义、单位和权重。不能从数据转换入口的配置推断训练设置。
- 对照与消融：**在相同数据划分下比较总次数截断 PIP/FI 与所用 SFI；分别改变关联阶、递推深度、基函数和角向通道，并在固定描述符数或固定网络参数量下补充公平对照。
- 误差与成本：**能量及实际训练的力的误差、关键反应或解离区域的单独误差；模板生成、描述符求值、网络推理和端到端耗时应分别报告，并注明硬件、精度、批量、线程数和是否计入输入输出。
- 实现核验：**小体系上的全部允许置换、平移/正交变换检验；递推与直接计算的一致性；第 S6 节反例回归测试；若实现力则进行有限差分、总力和总力矩检查；此外单独测试近共线、短距离和外推区域。

当前文档资料尚不足以确定这些体系级训练参数、误差和计时结果，因而此处不填入推测数值。参数示例中的递推阶数或映射常数也不能自动视为论文实验所用设置。

SI 补充参考文献

除正文列出的 Boutin–Kemper 两篇构型重构论文和 Pyykkö–Atsumi 共价半径表外，本 SI 使用以下基础来源：

4. G. Kemper, "Separating Invariants," *Journal of Symbolic Computation* **44**, 1212–1222 (2009). DOI: [10.1016/j.jsc.2008.02.012](https://doi.org/10.1016/j.jsc.2008.02.012); 作者公开稿。
5. NIST Digital Library of Mathematical Functions, Chapter 18, "Orthogonal Polynomials," 尤其是 §18.9: 递推与导数公式 和 §18.14: 不等式。